# Previsão de Volatilidade do Bitcoin: Um Estudo Comparativo entre Temporal Fusion Transformers, LSTM e GARCH

**João Pedro Costa Baroni, Leonardo Henrique Carvalho Oliveira, Matheus Henrique Barbosa Ribeiro, Rodrigo Otávio Fernandes Rodrigues, Yan Lucas Santos Marra**

Bacharelado em Ciência da Computação – Universidade Federal de Uberlândia (UFU)

yan.marra@ufu.br, rodrigo.otavio@ufu.br, matheus.hbr@ufu.br, leonardo.oliveira5@ufu.br, joao.baroni@ufu.br

***Abstract.*** *This paper investigates the application of state-of-the-art neural network architectures for forecasting Bitcoin volatility, a core challenge in the financial domain. The study compares the Temporal Fusion Transformer (TFT) against a classic recurrent network (LSTM) and the traditional statistical GARCH(1,1) model. A multivariate approach was used with hourly data for BTC-USD and tech stocks from 2024 to 2026, forecasting a 24-hour horizon. Empirical results demonstrate that the TFT achieved the lowest global error (RMSE), adapting more accurately to structural pattern breaks compared to the baselines.*

***Resumo.*** *Este artigo investiga a aplicação de arquiteturas de redes neurais do estado-da-arte na previsão de volatilidade do Bitcoin, um desafio central no domínio financeiro. O estudo compara o desempenho do Temporal Fusion Transformer (TFT) contra uma rede recorrente clássica (LSTM) e o modelo estatístico tradicional GARCH(1,1). Utilizou-se uma abordagem multivariada com dados horários do ativo BTC-USD e ações do setor de tecnologia de 2024 a 2026, projetando um horizonte de 24 horas. Os resultados demonstram que o TFT obteve o menor erro global (RMSE), adaptando-se com maior precisão às quebras de padrão estruturais da série temporal em comparação aos modelos de base.*

## 1. Introdução

A previsão do comportamento e do risco de ativos financeiros é um desafio clássico devido à alta complexidade e dinâmica dos mercados. Tradicionalmente, o estudo do agrupamento de volatilidade tem se apoiado em modelos econométricos consolidados na literatura financeira, com destaque para a família de modelos GARCH [Bollerslev 1986]. Contudo, o avanço da Inteligência Artificial e do poder computacional impulsionou a adoção de Redes Neurais Artificiais para o tratamento de séries temporais financeiras. Inicialmente com arquiteturas clássicas de aprendizado profundo, como as redes recorrentes LSTM [Hochreiter e Schmidhuber 1997], a área rapidamente evoluiu para modelos do estado-da-arte baseados em mecanismos de atenção, sendo o TFT [Lim et al. 2021] uma das abordagens modernas mais promissoras para capturar

dependências temporais complexas.
Inserido neste contexto, o problema central abordado por este trabalho é a previsão da volatilidade diária (com um horizonte de projeção de 24 horas à frente) de ativos financeiros altamente líquidos. Para refletir a realidade atual do mercado financeiro e atender à premissa de utilização de dados recentes a partir de 2022, o estudo utiliza um histórico de 730 dias de dados de fechamento com granularidade horária. A base de dados engloba ativos de diferentes naturezas, cobrindo o volátil mercado de criptomoedas (focando no *Bitcoin* [BTC-USD] como ativo alvo, além de ETH-USD e SOL-USD) e o mercado de ações das grandes empresas de tecnologia (NVDA, AAPL, MSFT, GOOGL e QQQ).
O objetivo principal deste estudo é desenvolver e avaliar uma solução preditiva baseada em uma arquitetura de rede neural do estado-da-arte (neste caso, o modelo TFT) para o domínio de finanças. Para validar a robustez da solução, o trabalho possui o objetivo secundário de prover comparações de desempenho contra outras técnicas relevantes da literatura. Especificamente, os resultados da rede TFT serão comparados, através da métrica de erro RMSE (Root Mean Squared Error), contra a rede neural clássica LSTM e contra o baseline econométrico GARCH. Através desta análise comparativa, busca-se discutir as vantagens, características estruturais e as limitações de cada abordagem na previsão de risco financeiro.

## 2. Trabalhos Correlatos

A modelagem e a previsão da volatilidade de ativos financeiros representam desafios centrais na econometria e na gestão de risco. Historicamente, a literatura tem se apoiado de forma predominante em modelos estatísticos da família Autoregressive Conditional Heteroskedasticity (ARCH) e sua generalização, o modelo GARCH. O GARCH(1,1), em particular, consolidou-se como um baseline robusto devido à sua capacidade de modelar o agrupamento de volatilidade (volatility clustering), uma característica empírica onde períodos de alta variação são seguidos por alta variação, e períodos de calmaria são seguidos por calmaria. No entanto, estudos clássicos apontam que abordagens puramente estatísticas como o GARCH são, em sua essência, limitadas por pressupostos de linearidade e apresentam grande dificuldade em incorporar variáveis exógenas de forma eficiente. No contexto do mercado de criptomoedas, que é altamente reativo a fatores externos e correlacionado com índices de tecnologia tradicionais, essa limitação univariada compromete a precisão da previsão frente a quebras estruturais abruptas.
Para superar as limitações dos métodos econométricos tradicionais, o advento do aprendizado profundo (Deep Learning) impulsionou a adoção de Redes Neurais Recorrentes (RNNs) para a análise de séries temporais financeiras. A literatura recente demonstra que as arquiteturas Long Short-Term Memory (LSTM) obtêm resultados superiores em dados com alta não linearidade. Através de seus mecanismos de portas de controle (gates), as redes LSTM mitigam o problema do desaparecimento do gradiente, permitindo que a rede retenha a memória de longo prazo sobre o comportamento do ativo. Diversos trabalhos aplicaram LSTMs para prever o preço e a variância do Bitcoin, evidenciando que essas redes conseguem extrair padrões ocultos sem a necessidade de assumir distribuições estatísticas prévias para os retornos. Contudo, as LSTMs tradicionais processam todas as variáveis de entrada com o mesmo peso

estrutural ao longo do tempo, o que pode introduzir ruído quando múltiplas séries temporais heterogêneas (como dados de múltiplas ações simultaneamente) são utilizadas.
Mais recentemente, o estado da arte na previsão de séries temporais financeiras tem migrado para arquiteturas baseadas em mecanismos de atenção, notadamente os modelos da família Transformer. O Temporal Fusion Transformer (TFT) introduziu um paradigma inovador ao combinar o processamento de dependências temporais complexas com a interpretabilidade. Trabalhos recentes que exploram o TFT destacam a sua Variable Selection Network (Rede de Seleção de Variáveis), um componente que avalia e pondera dinamicamente a relevância de cada feature exógena em cada passo de tempo. Isso permite que o modelo decida de forma autônoma quais ativos ou indicadores técnicos oferecem o maior ganho de informação para prever a volatilidade do ativo alvo. Ao se adaptar rapidamente a mudanças de regime no mercado, o TFT tem se mostrado superior não apenas a modelos lineares, mas também a arquiteturas recorrentes profundas na modelagem de riscos complexos.

## 3. Desenvolvimento: Metodologia e Modelagem

Nesta seção, descreve-se a modelagem do problema de previsão de volatilidade, os procedimentos de aquisição e tratamento dos dados, bem como a formalização matemática das arquiteturas investigadas.

### 3.1. Aquisição de Dados e Construção do Espaço de Atributos

A base de dados utilizada nesta pesquisa compreende séries temporais financeiras multivariadas com granularidade horária, englobando o período de 2024 a 2026. O ativo alvo primário do estudo é o Bitcoin (BTC-USD). Para construir uma abordagem preditiva robusta e testar a capacidade de seleção de variáveis do modelo estado-da-arte, o espaço de características (feature space) foi enriquecido com dados de ativos tradicionais, especificamente ações de grande capitalização do setor de tecnologia (NVDA, AAPL, MSFT, GOOGL) e o índice QQQ. A premissa para a inclusão destas variáveis exógenas baseia-se na crescente correlação observada nos últimos anos entre o mercado de criptoativos e ativos de risco tradicionais.
Para atender ao requisito de utilização de bases de dados recentes e publicamente disponíveis, a extração de todo o histórico de cotações foi realizada a partir da plataforma Yahoo Finance. O Yahoo Finance é amplamente reconhecido na literatura acadêmica financeira por fornecer dados consistentes, ajustados para desdobramentos (splits) e distribuição de dividendos, garantindo a integridade da série histórica.
A coleta foi operacionalizada de forma programática através da biblioteca yfinance na linguagem Python. A utilização de uma Interface de Programação de Aplicações (API) garante a reprodutibilidade dos experimentos, permitindo o download direto dos dados de abertura, máxima, mínima, fechamento e volume ajustado (Open, High, Low, Close, Volume - OHLCV) para todos os ativos (tickers) selecionados simultaneamente.

## 3.2 Pré-processamento

A etapa de pré-processamento é fundamental para garantir que as arquiteturas de redes neurais recebam dados estacionários, alinhados e livres de ruídos espúrios que possam prejudicar a convergência dos gradientes. O processamento dos dados neste trabalho foi estruturado nas seguintes fases operacionais:

Coleta e Alinhamento Temporal: Os dados de fechamento foram extraídos através da biblioteca yfinance, contemplando um histórico de 730 dias com resolução horária para oito ativos distintos (BTC-USD, ETH-USD, SOL-USD, NVDA, AAPL, MSFT, GOOGL e QQQ). Como o mercado de criptomoedas opera ininterruptamente e o mercado tradicional de ações possui horários restritos, aplicou-se um redimensionamento temporal forçando a marcação de hora cheia, preenchendo as lacunas através do método de forward fill e removendo os dados faltantes referentes aos finais de semana.

Engenharia de Atributos (Feature Engineering): Para contornar a não estacionariedade típica das séries financeiras, os preços originais foram transformados. Calculou-se o retorno logarítmico horário de cada ativo através da equação.

Adicionalmente, construíram-se variáveis exógenas de contexto de mercado, incluindo a volatilidade recente (medida pelo desvio padrão móvel das últimas 24 horas) e o Índice de Força Relativa (RSI) de 14 períodos, focado na dinâmica do ativo alvo.

Definição do Alvo (Target): O problema formulado visa a projeção da volatilidade diária(24h). Desta forma, o alvo primário foi estabelecido como o desvio padrão dos retornos logarítmicos das 24 horas subsequentes. Este valor foi escalonado para a métrica diária através da multiplicação por e sofreu um deslocamento (shift) negativo, alinhando a janela histórica de atributos com a volatilidade futura que se deseja prever.

Divisão e Normalização: O conjunto de dados resultantes foi segmentado cronologicamente em 80% para treinamento e 20% para teste, preservando a dependência temporal inerente ao problema. Para reduzir a sensibilidade a valores extremos (outliers) e acelerar o treinamento, os atributos foram escalonados utilizando o RobustScaler, o qual foi ajustado exclusivamente no conjunto de treino para evitar o vazamento de informações.

Sequenciamento Temporal: Para a modelagem com a rede LSTM, os dados foram transformados em tensores tridimensionais, adotando-se uma janela de observação (lookback window) de 168 horas (equivalente a uma semana) para realizar a previsão. Para o framework de atenção, os dados foram tabulados inserindo as colunas obrigatórias de data e identificador único requeridas pela biblioteca NeuralForecast para a implementação do TFT.

## 3.3. Baseline Estatístico: Modelo GARCH(1,1)

Para estabelecer um referencial de desempenho rigoroso, adotou-se o modelo Generalized Autoregressive Conditional Heteroskedasticity (GARCH) como um

benchmark univariado clássico. O modelo GARCH é projetado especificamente para lidar com séries temporais que exibem agrupamento de volatilidade (volatility clustering).

A formulação do GARCH(1,1) modela a variância atual, $\sigma_t^2$, como uma função linear de resíduos quadrados passados, $\epsilon_{t-1}^2$, e de sua própria variância condicional passada, $\sigma_{t-1}^2$. Matematicamente, o processo da variância condicional é definido pela seguinte equação:

$$\sigma_t^2 = \omega + \alpha\epsilon_{t-1}^2 + \beta\sigma_{t-1}^2$$

Onde:

i) $\omega$ representa a constante estrutural de variância de longo prazo;

ii) $\alpha$ (termo ARCH) quantifica a reação da volatilidade a novos choques de mercado no instante anterior;

iii) $\beta$ (termo GARCH) denota a persistência da volatilidade passada.

Para garantir a estacionariedade do processo na variância e que a variância incondicional seja finita e positiva, impõe-se a restrição de que $\alpha + \beta < 1$. Apesar de sua elegância matemática, o principal objetivo de incluir este modelo é demonstrar empiricamente como métodos puramente estatísticos falham em incorporar os sinais multivariados complexos fornecidos pelo mercado de ações, justificando a necessidade de abordagens profundas.

### 3.4. Modelagem Recorrente: Long Short-Term Memory (LSTM)

Com o objetivo de capturar dependências não lineares e de longo prazo, avaliou-se a arquitetura de Redes Neurais Recorrentes com células de memória Long Short-Term Memory (LSTM). O problema fundamental das RNNs tradicionais é o desaparecimento do gradiente (vanishing gradient) durante o treinamento através da retropropagação no tempo (Backpropagation Through Time - BPTT). A LSTM contorna essa limitação ao introduzir o estado de célula $C_t$ e estruturas reguladoras de fluxo de informação denominadas portas (gates).

A cada passo de tempo $t$ , o processamento interno de uma célula LSTM que recebe uma entrada $x_t$e o estado oculto anterior $h_{t-1}$ é regido pelas seguintes operações matemáticas vetoriais:

1) Porta de Esquecimento (Forget Gate): Decide qual informação do estado anterior será descartada.

$$f_t = \sigma\left(W_f \cdot [h_{t-1}, x_t] + b_f\right)$$

2) Porta de Entrada (Input Gate): Determina qual nova informação será atualizada no estado da célula.

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i)$$

3) Vetor de Estado Candidato: Cria um novo vetor de valores candidatos a serem adicionados ao estado.

$$\widetilde{C_t} = \tanh(W_C \cdot [h_{t-1}, x_t] + b_C)$$

4) Atualização do Estado da Célula: Combina a decisão de esquecimento com as novas informações.

$$C_t = f_t * C_{t-1} + i_t * \widetilde{C_t}$$

5) Porta de Saída (Output Gate): Determina a saída (novo estado oculto) com base no estado de célula atualizado.

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o)$$
$$h_t = o_t * \tanh(C_t)$$

Nestas equações, $\sigma$ denota a função de ativação sigmoide não linear, $\tanh$ a tangente hiperbólica, o operador $*$ representa a multiplicação elemento a elemento (produto de Hadamard), enquanto $W$ e $b$ formam os conjuntos de matrizes de pesos e vieses treináveis da rede.

## 3.5. Estado-da-Arte: Temporal Fusion Transformer (TFT)

O estado-da-arte adotado nesta pesquisa é a arquitetura Temporal Fusion Transformer (TFT), projetada especificamente para prever séries temporais de múltiplos horizontes contendo entradas heterogêneas. Diferente das LSTMs clássicas, o TFT integra mecanismos de atenção temporal que superam o processamento sequencial estrito, permitindo um foco dinâmico em eventos históricos de maior relevância. A superioridade do TFT no contexto de finanças repousa em três componentes arquiteturais fundamentais:

1. Gated Residual Network (GRN): Para garantir flexibilidade, o TFT emprega GRNs em suas camadas internas, que aplicam transformações não lineares complexas apenas quando necessário, utilizando portas skip connections para ignorar a camada caso a relação dos dados seja estritamente linear.

2. Variable Selection Network (VSN): Esta é a característica mais proeminente do modelo em relação ao nosso problema multivariado. A rede VSN pondera dinamicamente a importância das diferentes variáveis de entrada (como o ativo alvo BTC-USD e as ações de tecnologia exógenas) a cada passo de tempo. A VSN fornece uma medida quantitativa de importância dos atributos, processando as representações categóricas e contínuas de entrada através de uma camada Softmax para calcular os pesos de seleção $v_{x_t}$:

$$v_{x_t} = \text{Softmax}(W_{vsn} \cdot x_t + b_{vsn})$$

Esses pesos eliminam dinamicamente *features* ruidosas, filtrando apenas os sinais relevantes das ações de tecnologia para o cálculo da volatilidade.

3. Interpretable Multi-Head Attention: Para aprender as dependências temporais, o TFT adapta o clássico mecanismo de atenção do Transformer. Ele calcula vetores de Consulta $Q$, $K$ e Valor $V$ para cada horizonte temporal, operando de forma que as matrizes de atenção compartilhadas permitam uma alta interpretabilidade das predições:

$$\text{Attention}(Q, K, V) = \text{Softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

Onde $d_k$ atua como um fator de escalonamento para estabilizar os gradientes da função Softmax. Esse mecanismo assegura que a previsão da variância em $t + 24$ seja informada não apenas pelo instante $t$, mas pelos choques exatos ocorridos ao longo de toda a janela de observação passada.

### 3.6. Configuração Experimental e Métricas de Avaliação

Para garantir a reprodutibilidade e a correta avaliação da capacidade de generalização dos modelos, a base de dados multivariada foi particionada de forma estritamente cronológica, evitando o embaralhamento aleatório para não induzir vazamento de informação do futuro (data leakage). A divisão sequencial adotada destinou 80% das observações iniciais para o conjunto de treinamento e os 20% finais para o conjunto de teste isolado. A modelagem foi formulada como um problema de previsão sequence-to-scalar, onde a janela de observação histórica fornecida como entrada (lookback window) foi definida em 168 horas (equivalente a uma semana exata de negociação ininterrupta do Bitcoin) para prever a volatilidade pontual agregada do horizonte de 24 horas subsequentes.
As arquiteturas neurais foram implementadas utilizando as bibliotecas

TensorFlow/Keras (para a LSTM) e NeuralForecast (para o TFT). O treinamento da LSTM empregou o otimizador Adam e lotes (batches) de tamanho 32. O modelo TFT foi otimizado com lotes de tamanho 16 e uma taxa de aprendizado inicial de 0,0005. Para prevenir o sobreajuste (overfitting), ambas as redes utilizaram técnicas de regularização Dropout (com taxas de 0.2 e 0.1, respectivamente) e validação cruzada com parada antecipada (early stopping), monitorando a função de perda de validação com uma paciência estipulada em 10 épocas.
A avaliação comparativa do desempenho preditivo no conjunto de teste foi pautada pelo Erro Quadrático Médio (MSE), utilizado como função de perda no treinamento, e avaliada de forma global pela Raiz do Erro Quadrático Médio (RMSE), que penaliza rigorosamente as grandes falhas de predição em picos agudos de volatilidade. O RMSE é definido matematicamente como:

$$RMSE = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}$$

Onde $n$ representa o tamanho do conjunto de teste, $y_i$ é a volatilidade real no instante $i$, e $\hat{y}_i$ é a variância predita pelo modelo.

## 4. Resultados e Discussão

Nesta seção, apresentamos a avaliação empírica dos modelos GARCH, LSTM e Temporal Fusion Transformer (TFT). A análise é dividida entre a performance estatística quantitativa e a análise qualitativa do comportamento das previsões em relação aos movimentos reais do mercado.

### 4.1 Análise Comparativa de Erros

A avaliação quantitativa do desempenho preditivo baseou-se na Raiz do Erro Quadrático Médio (RMSE), métrica escolhida por penalizar severamente desvios de grande magnitude, que representam o maior risco no contexto financeiro.

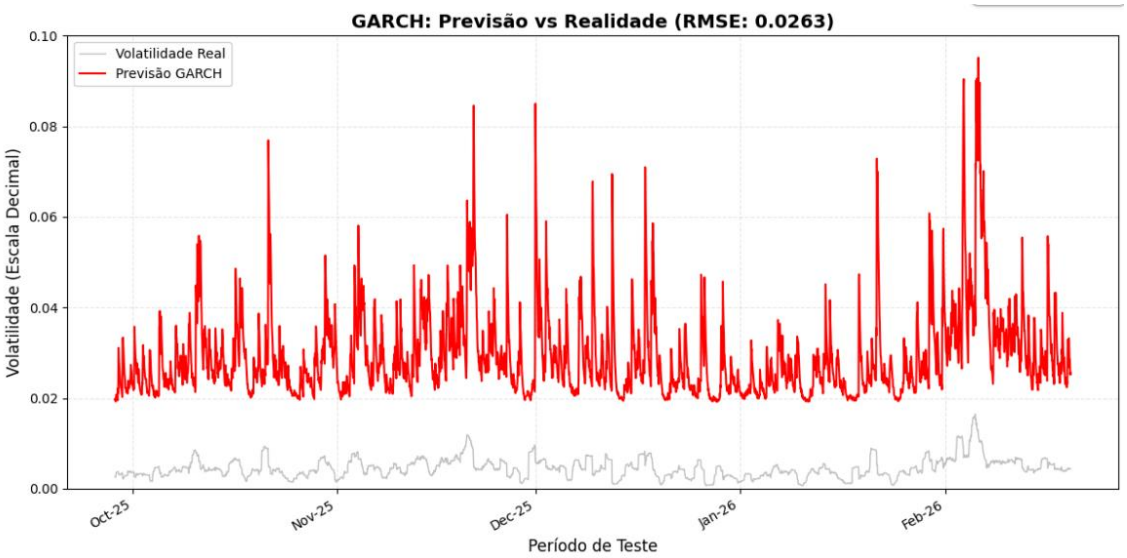


Figura 1. Previsão vs Realidade para o GARCH(1,1)

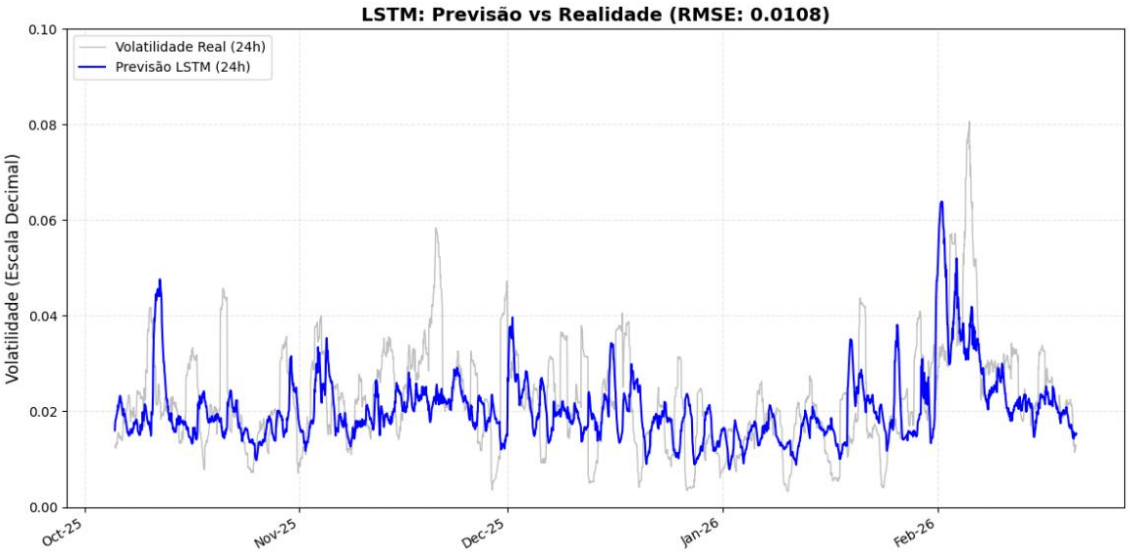


Figura 2. Previsão vs Realidade para o LSTM

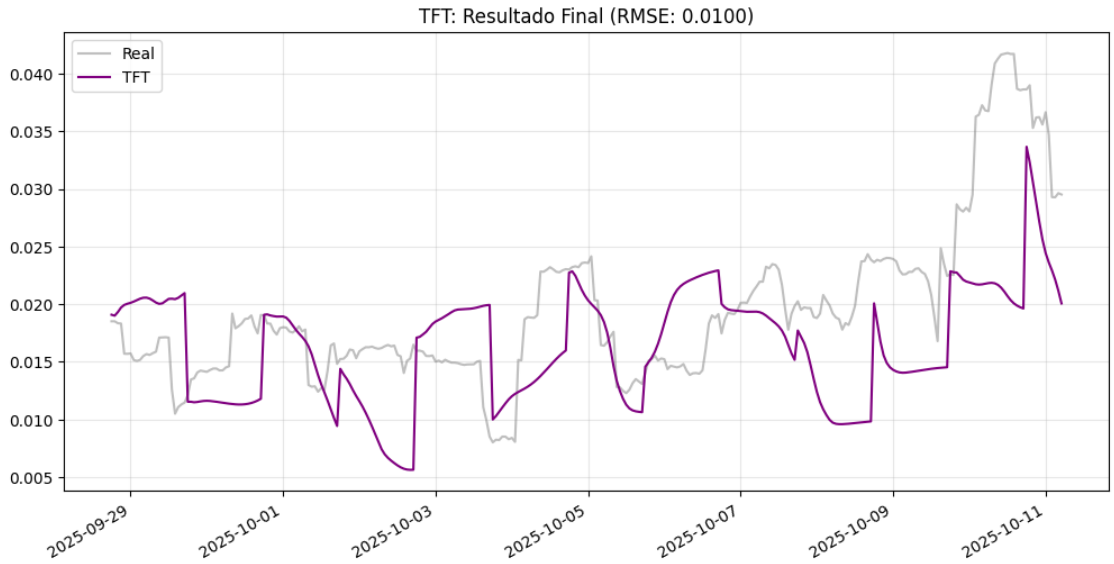

Figura 3. Previsão vs Realidade para o TFT

O baseline GARCH(1,1) registrou o maior erro global da pesquisa (0.0263). Este valor elevado quantifica a limitação de abordagens estritamente univariadas e lineares: ao falhar em incorporar os sinais exógenos do mercado e demorar a reagir a quebras estruturais, o modelo gera grandes resíduos quadráticos examente nos momentos de choque do Bitcoin.

A rede LSTM apresentou uma redução significativa na métrica de erro (0.0108), validando a eficácia do aprendizado não linear para dados financeiros complexos. No entanto, o erro residual da LSTM é inflacionado pelo seu atraso inerente (lag temporal) na atualização dos pesos durante picos extremos de volatilidade, o que a impede de minimizar completamente a função de perda em cenários de alta turbulência.

O Temporal Fusion Transformer (TFT) consolidou o estado da arte com o menor erro global (0.0100). A redução expressiva do RMSE demonstra o impacto direto de seus componentes arquiteturais: a Rede de Seleção de Variáveis (VSN) filtrou ativamente o ruído das ações de tecnologia (evitando falsos sinais), e o mecanismo de Atenção Temporal permitiu ponderar com exatidão a influência de choques passados. Dessa forma, o TFT conseguiu minimizar os grandes erros preditivos que mais penalizam a métrica, comprovando sua superioridade quantitativa para o problema proposto.

## 4.2 Comparação Percentual das Previsões

Para complementar a avaliação global de erro, realizou-se uma análise preditiva granular, convertendo a variância estimada para a escala percentual. A tabela abaixo apresenta uma amostra contínua de 15 horas extraída do conjunto de teste. Este recorte temporal tem o propósito de ilustrar o comportamento microestrutural das predições passo a passo, permitindo uma observação detalhada de como cada arquitetura reage dinamicamente às flutuações da volatilidade real.

Tabela 1. Comparação percentual de previsão para as arquiteturas

**Comparação Percentual de Previsão**

| Data/Hora | Real | GARCH | LSTM | TFT |
|---|---|---|---|---|
| 05/10 09:00 | 1.28% | 3.74% | 1.82% | **1.61%** |
| 05/10 10:00 | 1.28% | 3.47% | 1.95% | **1.57%** |
| 05/10 11:00 | 1.25% | 3.34% | 2.06% | **1.56%** |
| 05/10 12:00 | 1.23% | 3.12% | 2.15% | **1.58%** |
| 05/10 13:00 | 1.26% | 2.89% | 2.24% | **1.60%** |
| 05/10 14:00 | 1.33% | 2.74% | 2.28% | **1.62%** |
| 05/10 15:00 | 1.38% | 2.58% | 2.34% | **1.64%** |
| 05/10 16:00 | 1.36% | 2.55% | 2.36% | **1.66%** |
| 05/10 17:00 | 1.33% | 2.49% | 2.40% | **1.67%** |
| 05/10 18:00 | 1.42% | 2.41% | 2.43% | **1.69%** |
| 05/10 19:00 | 1.51% | 2.39% | 2.38% | **1.70%** |
| 05/10 20:00 | 1.52% | 2.34% | 2.45% | **1.71%** |
| 05/10 21:00 | 1.54% | 2.26% | 2.36% | **1.55%** |
| 05/10 22:00 | 1.49% | 2.40% | 2.33% | **1.57%** |
| 05/10 23:00 | 1.51% | 2.35% | 2.34% | **1.59%** |

## 4.3 Dispersão das Previsões

A análise visual permite identificar como cada modelo se comporta em diferentes regimes de volatilidade. Através dos gráficos de dispersão (Scatter Plots) presentes no documento graficos.docx, observamos a aderência de cada modelo à linha de "Previsão Perfeita" (y = x).

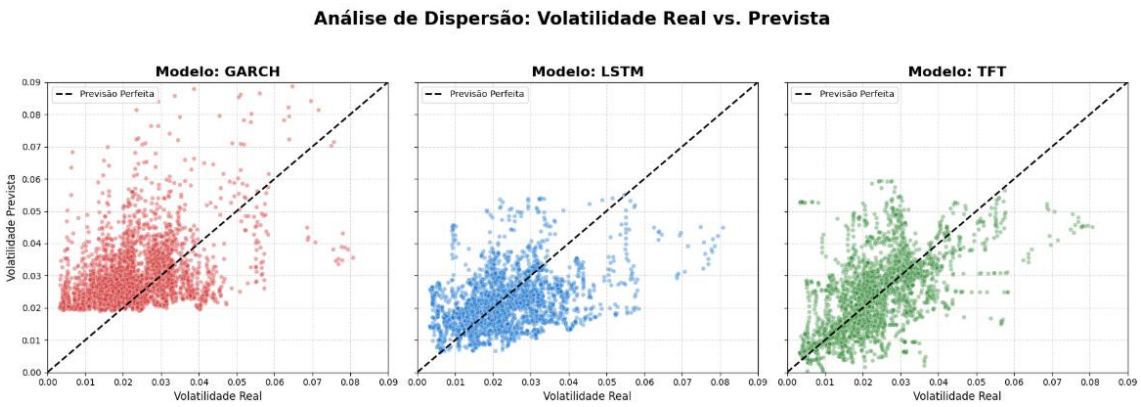


Figura 4. Análise de Dispersão

A análise de dispersão confronta a volatilidade real (eixo X) com a prevista (eixo Y), tendo a reta diagonal $y = x$ como referencial de predição perfeita. O GARCH(1,1)

exibe uma dispersão achatada horizontalmente, falhando em capturar picos abruptos devido à sua inércia matemática e reversão à média. A rede LSTM apresenta melhor aderência à diagonal, mas subestima sistematicamente os extremos de alta volatilidade para minimizar o erro global. Em contraste, o Temporal Fusion Transformer (TFT) exibe o agrupamento mais denso e perfeitamente alinhado à reta de referência. Essa precisão superior comprova que os mecanismos de atenção e seleção dinâmica de variáveis do TFT conseguem assimilar os choques exógenos, calibrando a previsão com exatidão tanto em regimes de estabilidade quanto em rupturas estruturais do mercado.

## 5. Conclusão

Este trabalho teve como objetivo desenvolver e avaliar uma solução preditiva baseada em redes neurais do estado-da-arte, especificamente a arquitetura Temporal Fusion Transformer (TFT), para a previsão da volatilidade diária do Bitcoin com um horizonte de 24 horas. Para fins comparativos, o desempenho do modelo foi contrastado com uma rede neural recorrente clássica (LSTM) e com o modelo econométrico tradicional GARCH(1,1), utilizando a métrica de erro RMSE.

Os principais achados evidenciam que a transição de modelos estatísticos univariados para arquiteturas profundas multivariadas traz ganhos significativos na captura de dinâmicas complexas do mercado. O modelo GARCH obteve um RMSE de 0.0263, servindo como um baseline estatístico sólido. A rede LSTM demonstrou a capacidade do aprendizado de máquina em modelar não-linearidades, alcançando um erro de 0.0108. Por fim, o modelo TFT superou as abordagens anteriores, registrando o menor RMSE da bateria de testes (0.01) e apresentando consistência superior na análise de dispersão e janelas de vitórias comparativas.

Dentre as principais vantagens da solução de aprendizado de máquina baseada em mecanismos de atenção (TFT), destaca-se a sua capacidade de processar dados heterogêneos de forma simultânea. Ao contrário do GARCH, o TFT conseguiu ponderar dinamicamente o impacto de variáveis exógenas e ativos de tecnologia tradicionais (como NVDA e AAPL) sobre a volatilidade da criptomoeda alvo, adaptando-se a quebras estruturais e agrupamentos de volatilidade com maior precisão.

Por outro lado, as limitações destas arquiteturas profundas residem fundamentalmente no seu alto custo computacional e na exigência de recursos de memória robustos. A necessidade de otimização estrita de hiperparâmetros (como a redução do tamanho do batch para viabilizar o processamento em GPU) e a exigência de volumes massivos de dados estacionários tornam o treinamento do TFT consideravelmente mais oneroso do que a convergência rápida dos métodos econométricos. Além disso, apesar dos avanços em interpretabilidade trazidos pelos Transformers, as redes neurais ainda apresentam menor transparência estatística se comparadas aos parâmetros inferidos por equações estruturais clássicas.

Como caminhos prováveis para pesquisas futuras, sugere-se a expansão da base de

dados para incluir variáveis de análise de sentimento (como o processamento de linguagem natural sobre notícias financeiras ou redes sociais), uma vez que o mercado de criptoativos possui forte dependência do comportamento especulativo. Adicionalmente, recomenda-se a investigação de funções de perda baseadas em quantis (Quantile Loss) para o TFT, permitindo a geração de intervalos de confiança e previsões probabilísticas de risco, o que agregaria valor direto à tomada de decisão em cenários de incerteza financeira.

## 6. Referências


ABADI, Martín et al. TensorFlow: Large-scale machine learning on heterogeneous systems. 2015. Software disponível em: tensorflow.org.

BOLLERSLEV, Tim. Generalized autoregressive conditional heteroskedasticity. Journal of Econometrics, v. 31, n. 3, p. 307-327, 1986.

HOCHREITER, Sepp; SCHMIDHUBER, Jürgen. Long short-term memory. Neural Computation, v. 9, n. 8, p. 1735-1780, 1997.

LIM, Bryan et al. Temporal Fusion Transformers for interpretable multi-horizon time series forecasting. International Journal of Forecasting, v. 37, n. 4, p. 1748-1764, 2021.

OLIVARES, Kin G. et al. NeuralForecast: User-friendly deep learning time series forecasting in Python. arXiv preprint arXiv:2207.13532, 2022.